IAE Nantes
Économie & Management
Pôle Sociétés

Nantes Université

Nantes Université

Dossier Régression Pénalisées

M2 ECAP

Analyse du taux d'emploi au Royaume-Uni

Dossier réalisé par :

Lomane Mesnil

Elise Brochard

Année universitaire 2026-2027

Sommaire

1) Analyse exploratoire **2**

a) Présentation des données 2

b) Analyse des valeurs manquantes 2

c) Graphique de la variable à expliquer stationnaire 2

d) Statistiques descriptives de la variable à expliquer 3

e) Analyse de la corrélation entre les variables 5

2) Sélection des variables **8**

a) Comparaison des modèles estimés 8

b) Choix du meilleur modèle 11

Conclusion **13**

Annexes **14**

1) Analyse exploratoire

a) Présentation des données

Pour ce projet nous travaillerons sur le taux d'emploi au Royaume-Uni. Les données proviennent de la base de données du Royaume-Uni mise à disposition par la Chaire en macroéconomie et prévisions de l'ESG UQAM[1]. Pour notre analyse, nous avons conservé la variable EMP_RATE qui correspond au taux d'emploi comme variable à expliquer. On retrouve dans la base de données également 112 variables macroéconomiques susceptibles d'influencer le taux d'emploi, telles que l'activité économique, les prix, les taux d'intérêt ou encore le marché du travail. Les données sont de fréquence mensuelle et couvrent la période : janvier 1998 — décembre 2025 (336 observations). Les données n'étant pas complètes pour les mois de l'année 2026, celles-ci ne sont pas utilisées dans notre étude.

b) Analyse des valeurs manquantes

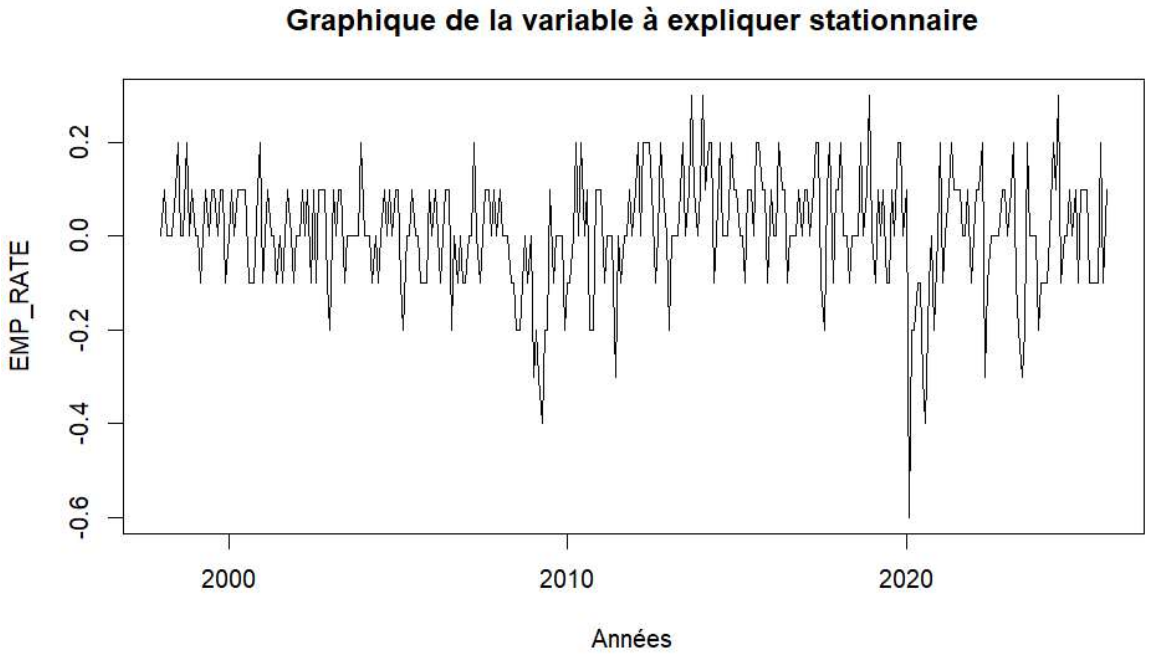
Dans notre base de données les valeurs manquantes ont été remplacées par un algorithme EM. Cependant, il persistait 22 valeurs manquantes sur la variable LIBOR_3mth, qui est le taux interbancaire LIBOR à 3 mois, cette variable a donc été supprimée de la base afin de garantir la fiabilité de notre analyse. De plus, étant donné que les mois de janvier et février 2026 comportaient encore des valeurs manquantes, ceux-ci ont été enlevés de notre base finale. En effet, la présence de ces données incomplètes aurait biaisé nos estimations. Finalement, la base comprend 111 variables explicatives et 1 variable à expliquer.

c) Graphique de la variable à expliquer stationnaire

La variable à expliquer de notre étude (EMP_RATE) étant déjà stationnaire, ce qui est confirmé par le test de Dickey-Fuller augmenté (ADF), aucune transformation supplémentaire n'a été nécessaire avant de procéder à l'analyse (cf. Annexe 1).

[1] Base de données du Royaume-Uni - Chaire en macroéconomie et prévisions - ESG UQAM

Graphique 1 : Evolution du taux d'emploi au Royaume-Uni (série stationnaire, 1998—2025)



Source : Autrices

Ce graphique représente les fluctuations en différences premières du taux d'emploi au Royaume-Uni au cours du temps (1998—2025). On observe 2 pics à la baisse relativement marquée : autour de 2008 (crise des subprimes) et autour de 2020 (COVID 19), ce qui correspond aux 2 crises économiques majeures du XXIe siècle. On remarque qu'après les crises il faut environ 2 à 3 années pour revenir aux fluctuations qu'on observait avant la crise. En dehors de ces périodes, le taux d'emploi semble relativement stable sur la série rendue stationnaire.

d) Statistiques descriptives de la variable à expliquer

Table 1 : Statistiques descriptives du taux d'emploi

Statistiques	Valeurs
Minimum	- 0,600
Médiane	0
Moyenne	0,012

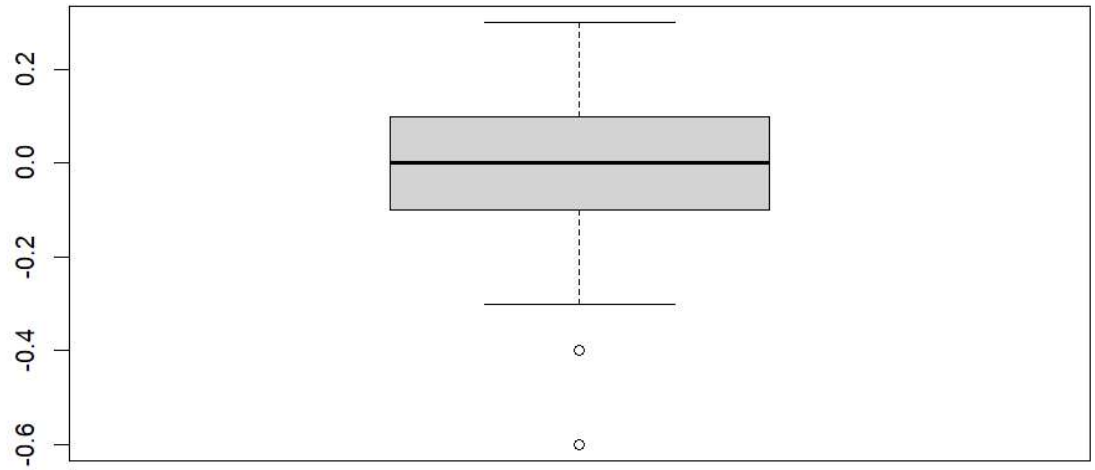
Maximum	0,300
Variance	0,015
Ecart-type	0,124

Source : Autrices

Les statistiques descriptives montrent que les variations du taux d'emploi sont globalement proches de zéro. En effet, la moyenne est de 0,012 et la médiane est égale à 0, ainsi, les variations sont relativement faibles sur l'ensemble de la période. On remarque cependant une différence entre les valeurs extrêmes, avec un minimum de -0,600 contre un maximum de 0,300. Cela montre que certaines périodes ont connu des variations négatives du taux d'emploi plus importantes que les variations positives observées.

L'écart-type est de 0,124, ce qui indique une faible dispersion des observations autour de la moyenne, malgré la présence de quelques valeurs extrêmes. Le boxplot permet de compléter cette analyse en mettant en évidence la dispersion des données et les observations les plus éloignées.

Graphique 2 : Boxplot de la variable à expliquer



Source : Autrices

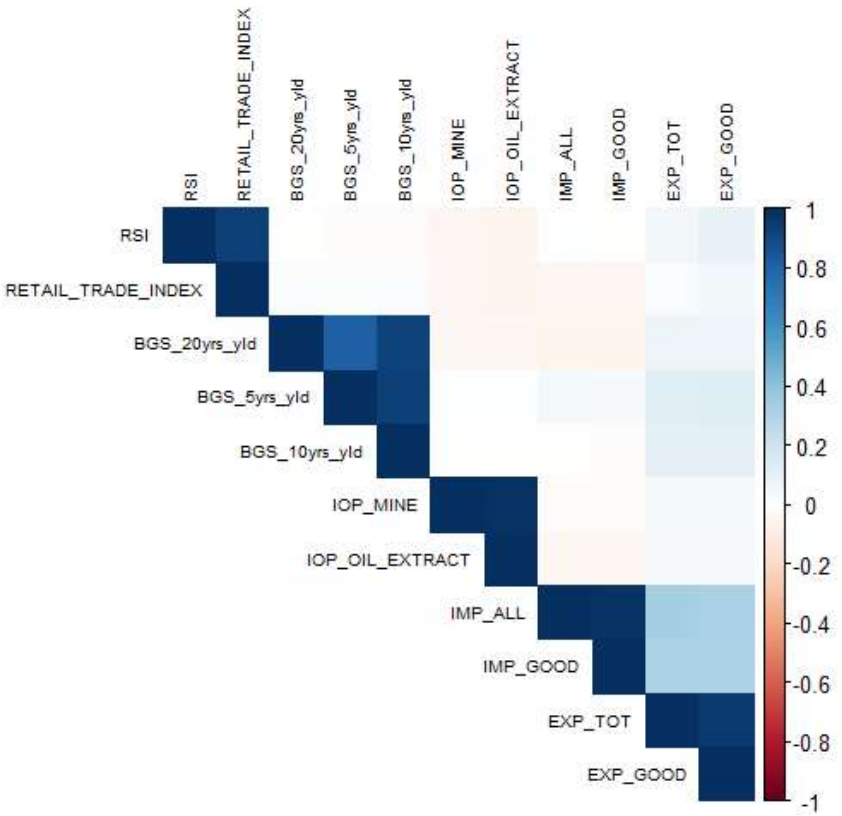
On peut distinguer deux valeurs extrêmes sur le boxplot, autour de -0,4 et -0,6. La valeur de -0,6 est considérée comme atypique d'après le test de Rosner (cf. Annexe 2). Cependant, nous avons choisi de la conserver, car elle correspond à une variation réelle du taux d'emploi lors du début de la crise COVID et non à une erreur dans les données.

e) Analyse de la corrélation entre les variables

Puisque nous avons un grand nombre de variables dans cette étude (111), nous analysons la corrélation entre ces dernières afin de garantir des résultats fiables.

Étant donné le grand nombre de variables dans notre base de données, nous avons choisi de n'afficher, dans la matrice de corrélation de Spearman, qu'un sous-ensemble de variables. Seules celles présentant un coefficient de corrélation supérieur à 0,9 avec au moins une autre variable ont été retenues.

Graphique 3 : Matrice de corrélation de Spearman



Source : Autrices

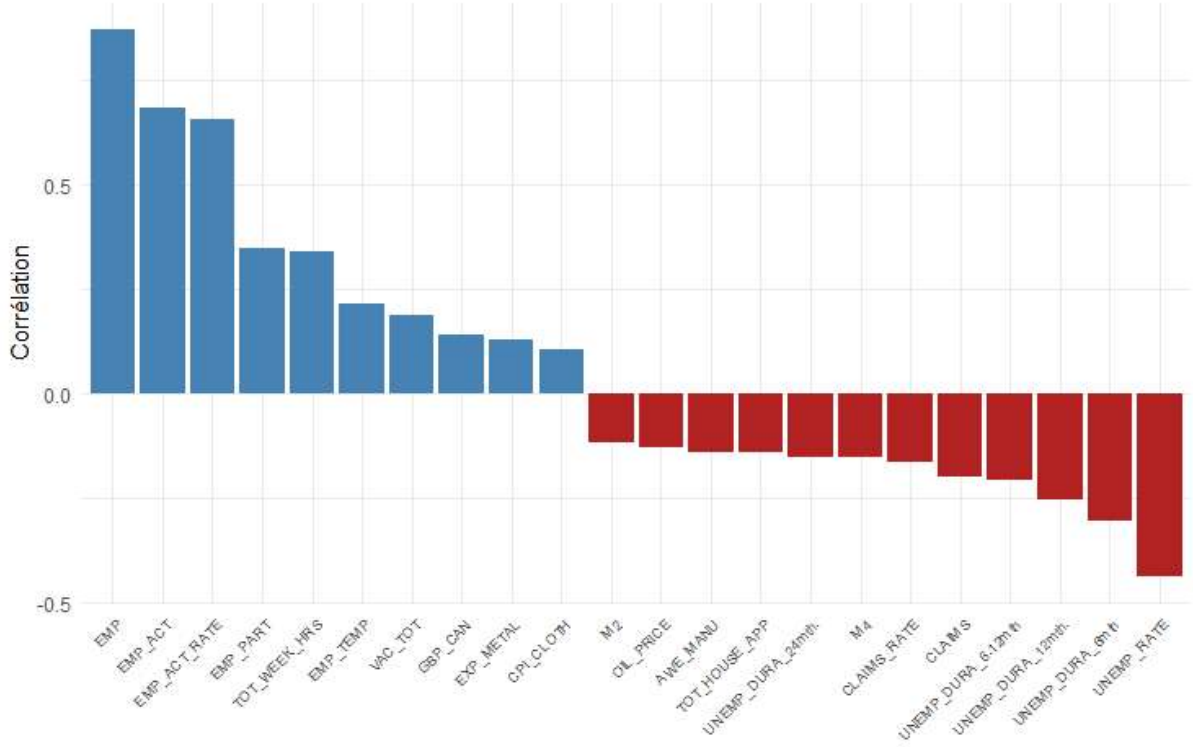
Parmi les 110 variables explicatives de notre base, l'observation de leur corrélation deux à deux révèle que certaines d'entre elles sont fortement liées. Le graphique ci-dessus, construit avec un seuil de 0,9 pour ne faire ressortir que les relations les plus fortes, met en évidence cinq groupes de variables présentant une corrélation quasi-parfaite entre elles.

On y retrouve notamment les trois taux obligataires britanniques à différentes maturités (BGS_5yrs_yld, BGS_10yrs_yld, BGS_20yrs_yld), qui évoluent de façon quasiment identique, ainsi que deux paires de variables mesurant des phénomènes très proches par construction : les importations et exportations totales versus celles portant uniquement sur les biens (IMP_ALL/IMP_GOOD et EXP_TOT/EXP_GOOD), l'extraction minière et pétrolière (IOP_MINE/IOP_OIL_EXTRACT), ainsi que les indices de vente au détail (RSI/RETAIL_TRADE_INDEX).

Ces fortes corrélations restent ici limitées à des paires ou petits groupes thématiques isolés, sans lien apparent entre les différents blocs, comme le montre le reste de la matrice, resté quasiment blanc. Cela reflète surtout la présence, dans la base, de plusieurs indicateurs mesurant une même réalité économique sous des angles différents.

Afin de compléter l'analyse des corrélations, on représente sous forme de barplot les variables qui sont liées avec la variable à expliquer.

Graphique 3 : Corrélation entre les variable explicatives et EMP_RATE



Source : Autrices

Ce graphique montre les variables explicatives ayant une corrélation d'au moins 0,1 (en valeur absolue) avec EMP_RATE, classées de la plus positive à la plus négative.

On voit que EMP, EMP_ACT et EMP_ACT_RATE sont les plus corrélées positivement avec EMP_RATE, ce qui est logique puisque ce sont des mesures très proches de l'emploi. À l'inverse, UNEMP_RATE (taux de chômage) ressort comme la corrélation négative la plus forte, ce qui est cohérent économiquement : plus le chômage augmente, plus le taux d'emploi baisse.

On retrouve aussi plusieurs variables liées à la durée du chômage (UNEMP_DURA_6mth, UNEMP_DURA_12mth, UNEMP_DURA_24mth) toutes négativement corrélées, ainsi que CLAIMS et CLAIMS_RATE (demandes d'allocations chômage), ce qui va dans le même sens.

Globalement, ce graphique confirme que les variables les plus corrélées à EMP_RATE sont surtout des variables directement liées à l'emploi et au chômage, ce qui est attendu, alors que les autres variables (prix, taux de change, indices boursiers) ont des corrélations plus faibles avec la cible.

Le tableau en Annexe 3, croise les variables corrélées à EMP_RATE (seuil ≥ 0,1) avec celles identifiées précédemment comme fortement corrélées entre elles (seuil ≥ 0,9). On remarque qu'aucune des variables les plus liées à notre variable cible ne présente de corrélation forte avec une autre variable de la base.

2) Sélection des variables

L'analyse exploratoire a montré l'utilité d'une méthode de sélection des variables par régressions pénalisées. La section suivante présente les estimations des modèles utilisés.

a) Comparaison des modèles estimés

Le tableau ci-dessous nous indique les hyperparamètres retenus pour les différentes méthodes. Pour chacune d'entre elles nous avons choisi d'estimer le lambda.lse qui correspond au lambda le plus grand dont l'erreur est à moins d'un écart-type de l'erreur minimale.
Notre objectif était d'avoir les meilleurs modèles explicatifs possibles, raison pour laquelle nous avons choisi le lambda.lse.

Table 2 : Tableau des estimations des hyperparamètres

Paramètre	Ridge	Lasso	Elastic.Net.Fixed	Elastic.Net.Grid.Search	SCAD	Adaptive.Lasso.Lasso	Adaptive.Lasso.Ridge
Lambda	0.46416	0.0343	0.08697	0.04977	0.02917	0.02511	0.08793
Alpha	0.00000	1.0000	0.50000	0.60000	-	-	-

Source : Autrices

Les λ ne sont pas comparables d'une méthode à l'autre, car chaque pénalité a sa propre échelle : le λ de Ridge (0,464) est le plus élevé, mais Ridge ne supprime aucune variable, alors que l'Adaptive Lasso - Ridge, avec un λ de 0,088, n'en garde que 5.
Le paramètre α arbitre entre Ridge (α = 0) et Lasso (α = 1). L'Elastic Net à α = 0,5 (λ = 0,087) retient 8 variables, et celui de la grid search (α = 0,6, λ = 0,05) en retient 15. SCAD (λ = 0,029) en garde 15, et l'Adaptive Lasso en garde 18 avec les poids Lasso (λ = 0,025) et 5 avec les poids Ridge (λ = 0,088).

Table 3 : Tableau comparatif des modèles, comparaison des betas

Variables	MCO	Ridge	LASSO	Elastic-Net (fixed 0.5)	Elastic-Net (grid search)	a.Lasso - Ridge	a.Lasso - Lasso	SCAD
EMP	0.16*	0.256	0.378	0.383	0.361	0.571	0.539	0.213
EMP_PART		0.031					-0.002	
UNEMP_RATE	-0.167***	-0.151	-0.155	-0.172	-0.151	-0.175	-0.092	-0.117
UNEMP_DURA_6mth	-0.281***	-0.143	-0.162	-0.129	-0.172	-0.003	-0.148	-0.295
UNEMP_DURA_6.12mth	-0.16***	-0.08	-0.08	-0.062	-0.087		-0.072	-0.174
UNEMP_DURA_12mth.	-0.178***	-0.084	-0.071	-0.055	-0.078		-0.07	-0.152
EMP_ACT	0.593***	0.229	0.303	0.255	0.300	0.097	0.184	0.619
EMP_ACT_RATE		0.191	0.138	0.156	0.156	0.106	0.141	
AWE_MANU		-0.041			-0.001		-0.004	
AWE_PRIV	-0.059*	-0.034	-0.026	-0.017	-0.028		-0.036	-0.027
AWE_PUB		-0.02			-0.002		-0.008	
IOP_NON_DUR		0.01					0.001	0.002
IOS_45	0.296**	0.014						
IOS_46	0.227*	0.012						

CPIH_ALL	-0.175*	-0.006	-0.002		-0.003		-0.004	-0.01
CPI_GOOD	0.195**	0.009						
CPI_SERV		-0.004						-0.006
RPI_SERV		-0.007	-0.004		-0.007		-0.019	
EXP_METAL		0.033	0.006		0.011		0.015	0.003
TOT_LENDING_APP		0.006						0.007
TOT_HOUSE_APP		0.002						0.027
FTSE250		-0.018	-0.008		-0.011		-0.024	
UK_focused_equity		-0.011	-0.004		-0.006		-0.005	-0.021
BCI	0.072**	0.022						
PPI_MACH		-0.01					-0.006	

Source : Autrices
*Note : Seuils de significativité pour la méthode MCO : *** p<0,01 / ** p<0,05 / * p<0,1*

Le tableau ci-dessus regroupe les coefficients sur les variables retenues pour chaque méthode.

On remarque d'abord que les méthodes pénalisées réduisent fortement les coefficients du MCO. Par exemple, EMP_ACT vaut 0,593 avec le MCO contre 0,229 avec le Ridge. Le MCO est présenté uniquement à titre de comparaison, car ses coefficients sont instables avec autant de variables proches entre elles.

Quatre variables sont retenues par toutes les méthodes pénalisées, avec le même signe. EMP et EMP_ACT ont un effet positif, et UNEMP_RATE et UNEMP_DURA_6mth un effet négatif. C'est cohérent : plus l'emploi augmente, plus le taux d'emploi augmente, et plus le chômage augmente et dure longtemps, plus il baisse.

Globalement, les variables ont le même signe pour chaque méthode, la seule exception étant la variable EMP_PART qui vaut 0,031 avec la méthode Ridge contre -0,002 avec la méthode Adaptive Lasso Lasso. N'étant pas une variable retenue pour les autres modèles, nous ne l'interpréterons pas. Les autres variables qui reviennent le plus souvent sont :

- UNEMP_DURA_6.12mth, AWE_PRIV, CPIH_ALL et UK_focused_equity : avec un coefficient négatif
- EMP_ACT_RATE et EXP_METAL : avec un coefficient positif

b) Choix du meilleur modèle

Table 4 : Tableau comparatif des performances

Méthode	Nombre de variables	R2 in sample	CV MSE
MCO	12 (significatives)	0.910	0.244
Ridge	109	0.867	0.185
Lasso	13	0.870	0.141
Elastic-Net (fixed)	8	0.862	0.146
Elastic-Net (grid)	15	0.871	0.140
A.Lasso Lasso	18	0.868	0.147
A.Lasso Ridge	5	0.827	0.137
SCAD	15	0.880	0.132

Source : Autrices

Le tableau comparatif des performances montre des R2 in sample élevés (entre 0.82 et 0.91) pour tous les modèles.

Malgré son R2 le plus élevé, la méthode MCO obtient la plus haute valeur pour le CV MSE, montrant une moins bonne performance prédictive que les modèles avec sélection de variables.

Ces dernières ont donc des R2 élevés combinés à des CV MSE plus bas. Parmi elles, le modèle SCAD semble être le meilleur compromis entre qualité d'ajustement et pouvoir explicatif. En effet, avec un des R2 les plus forts dans la liste (0.880), le CV MSE (0.132) le plus bas, et une sélection de seulement 15 variables; ce modèle s'impose comme l'un des plus performants et équilibrés. En comparaison, le modèle Elastic-Net (grid search) retient également 15 variables mais possède un R2 plus faible que le SCAD et un CV MSE plus élevé. Le Lasso, qui garde 13 variables, a un R2 proche de celui du SCAD (0,870) et un CV MSE légèrement plus élevé (0,141). Les écarts de CV MSE entre ces modèles restent faibles : leurs performances sont donc comparables, et le choix du SCAD repose surtout sur son meilleur ajustement.

Enfin, parmi les 15 variables sélectionnées par le modèle SCAD, certaines se distinguent par l'intensité de leur impact. C'est le cas notamment de la variable EMP_ACT (coefficient de 0.619), qui exerce l'influence positive la plus forte, ou à l'inverse de la durée de chômage jusqu'à 6 mois UNEMP_DURA_6mth (-0.295), qui elle pèse négativement.

Conclusion

En conclusion, cette étude a permis de montrer l'intérêt des méthodes de pénalisation et de sélection de variables par rapport aux moindres carrés ordinaires (MCO) pour l'analyse.

Parmi l'ensemble des approches évaluées , le modèle le plus efficace semble être le SCAD, en combinant à la fois une excellente qualité d'ajustement et la plus faible erreur de prédiction. Sur le plan pratique, l'analyse des coefficients met en évidence le rôle déterminant des indicateurs du marché du travail britannique : notamment la population active (EMP_ACT) qui exerce l'impact positif le plus marqué, et la durée du chômage jusqu'à 6 mois (UNEMP_DURA_6mth) qui pèse le plus négativement. Ces facteurs clés constituent ainsi des leviers majeurs à suivre pour appréhender l'évolution du taux d'emploi au Royaume-Uni.

Annexes

Annexe 1 : Résultat du test de stationnarité (ADF) sur la variable EMP_RATE

```
> adf.test(base$EMP_RATE)$p.value
[1] 0.01
```

Annexe 2 : Résultats du Rosner Test sur la variable EMP_RATE

```
  i     Mean.i      SD.i Value Obs.Num    R.i+1 lambda.i+1 Outlier
1 0 0.01160714 0.1241657  -0.6     266 4.925735   3.755322    TRUE
2 1 0.01343284 0.1197496  -0.4     136 3.452477   3.754492   FALSE
3 2 0.01467066 0.1177634  -0.4     272 3.521220   3.753660   FALSE
```

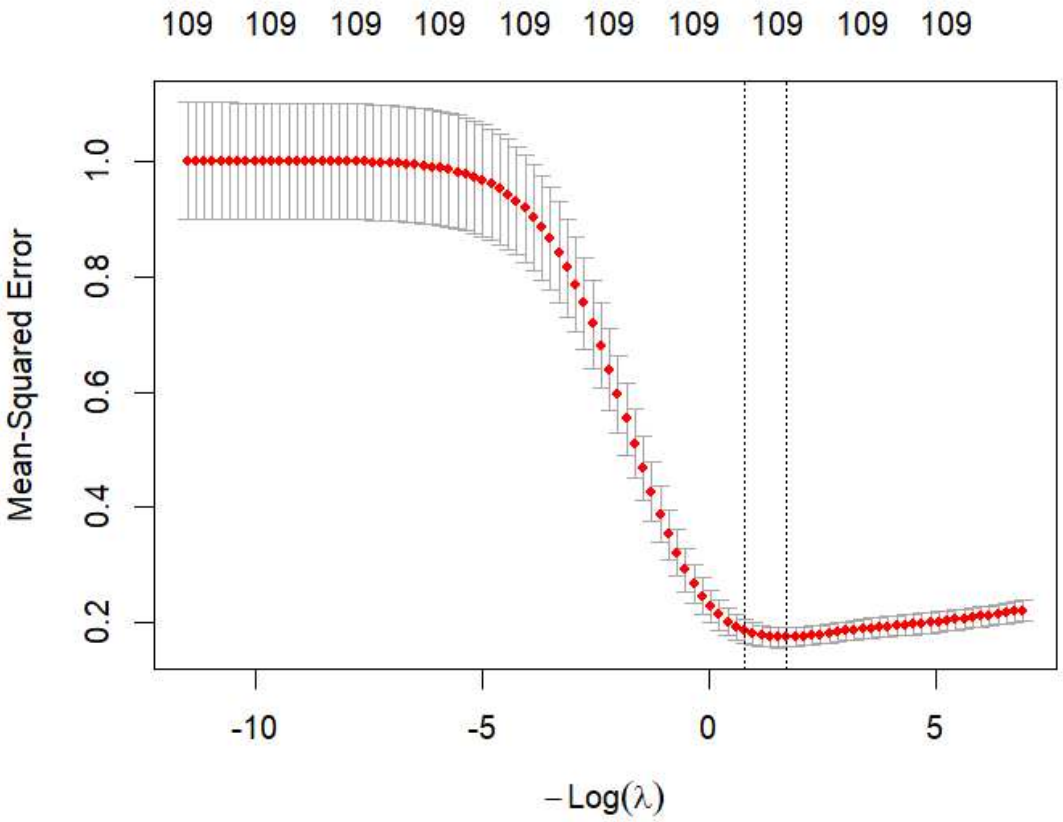
Annexe 3 : Corrélation entre les variables explicatives et la variable à expliquer

Variable	Corrélation avec EMP_RATE	Corrélation avec une autre variable
EMP	0,872	FALSE
EMP_ACT	0,685	FALSE
EMP_ACT_RATE	0,657	FALSE
UNEMP_RATE	-0,437	FALSE
EMP_PART	0,349	FALSE
TOT_WEEK_HRS	0,338	FALSE
UNEMP_DURA_6mth	-0,305	FALSE
UNEMP_DURA_12mth.	-0,254	FALSE
EMP_TEMP	0,216	FALSE
UNEMP_DURA_6.12mth	-0,208	FALSE
CLAIMS	-0,200	FALSE
VAC_TOT	0,189	FALSE
CLAIMS_RATE	-0,164	FALSE
M4	-0,153	FALSE
UNEMP_DURA_24mth.	-0,152	FALSE
GBP_CAN	0,141	FALSE
TOT_HOUSE_APP	0,140	FALSE

AWE_MANU	-0,138	FALSE
EXP_METAL	0,129	FALSE
OIL_PRICE	-0,128	FALSE
M2	-0,115	FALSE
CPI_CLOTH	0,107	FALSE

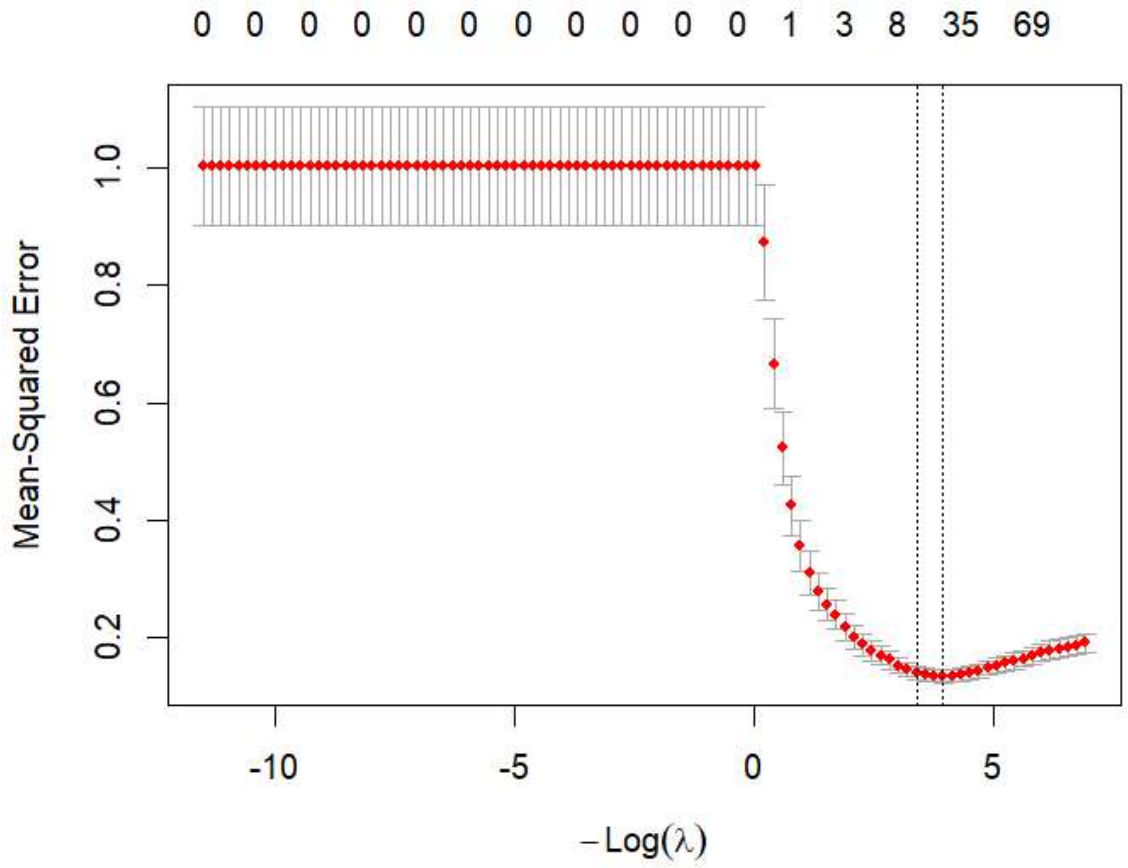
Source : Autrices

Annexe 4 : Courbe des lambdas avec la méthode Ridge



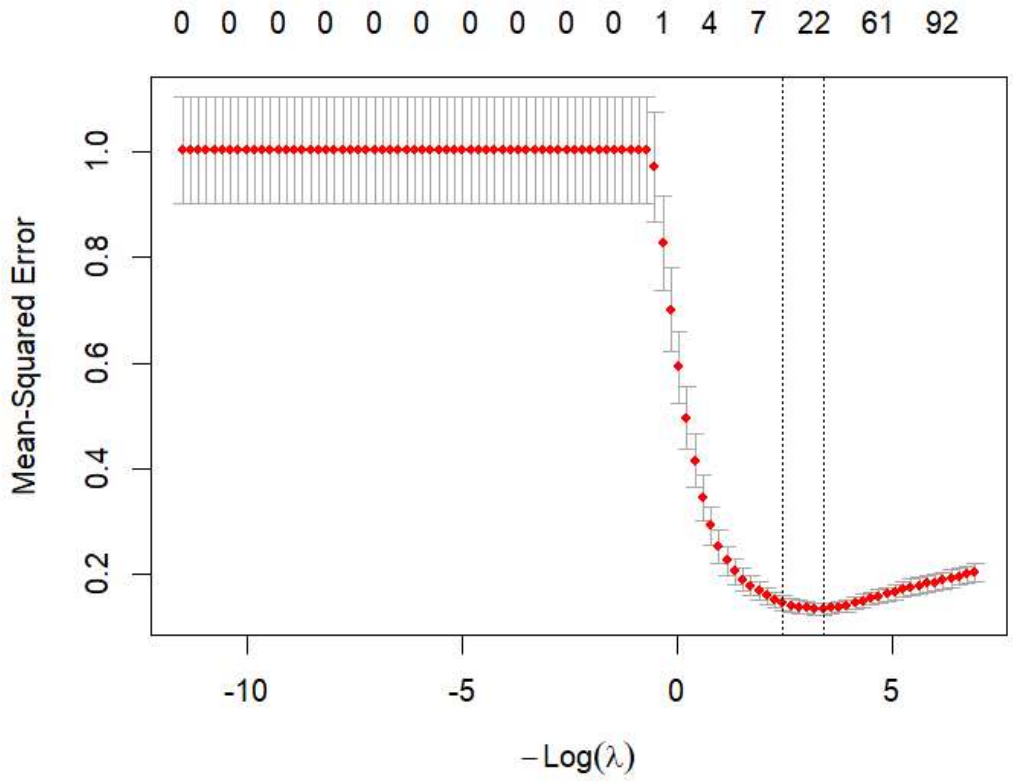
Source : Autrices

Annexe 5 : Courbe des lambdas avec la méthode Lasso



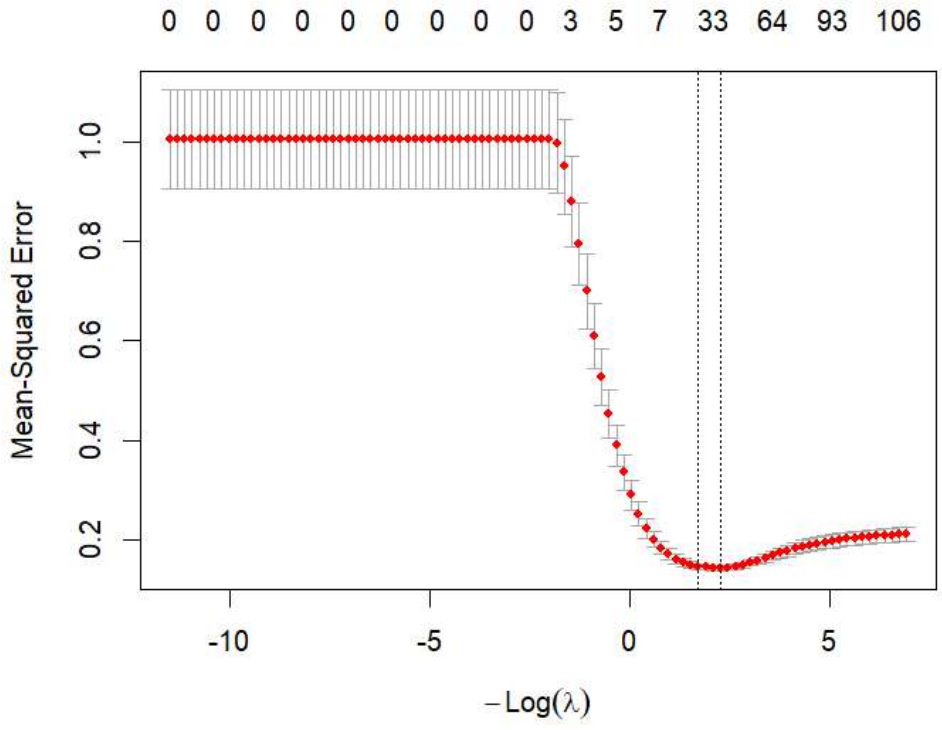
Source : Autrices

Annexe 6 : Courbe des lambdas avec la méthode Elastic Net (fixed)



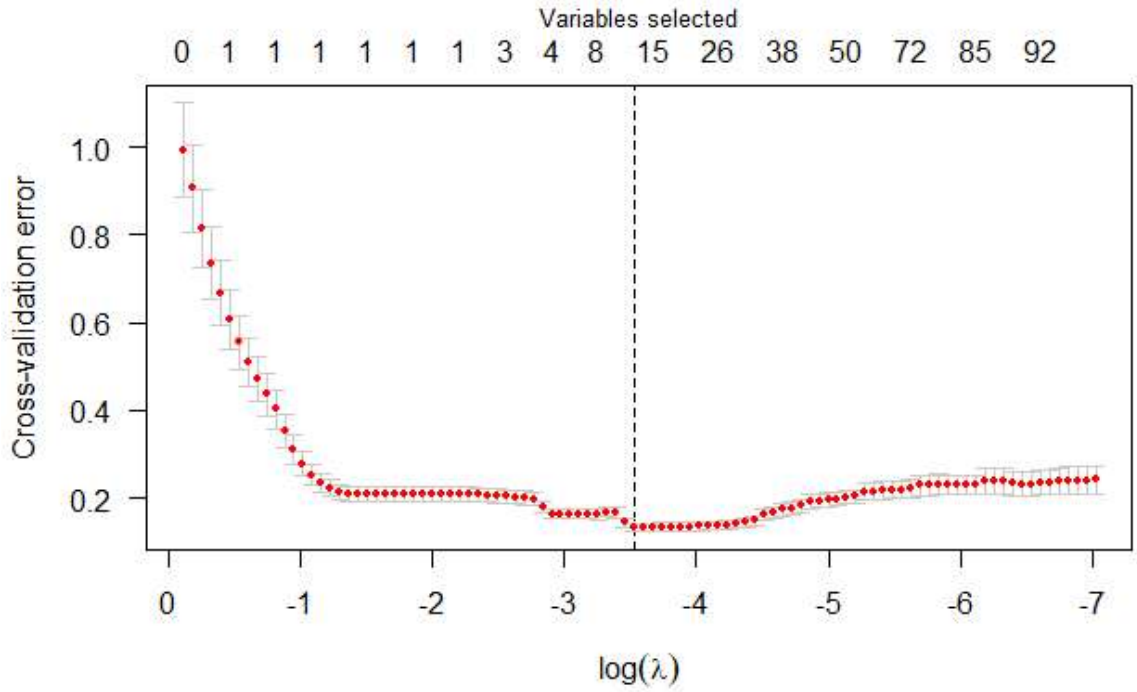
Source : Autrices

Annexe 7 : Courbe des lambdas avec la méthode Elastic Net (Grid Search)



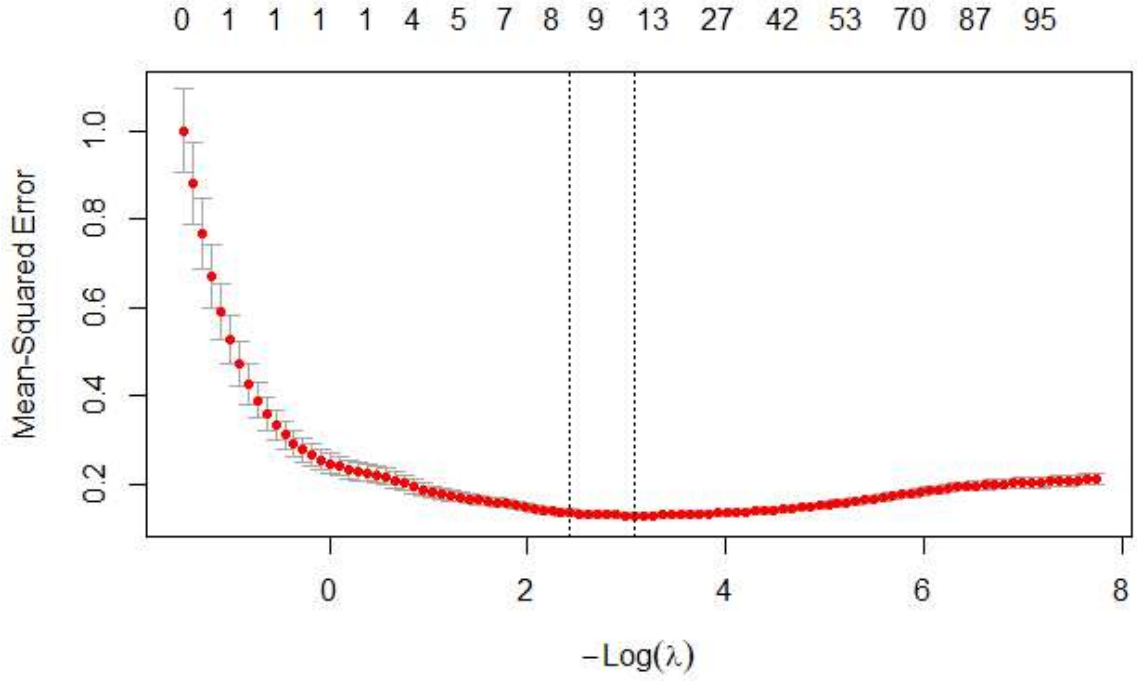
Source : Autrices

Annexe 8 : Courbe des lambdas avec la méthode SACD



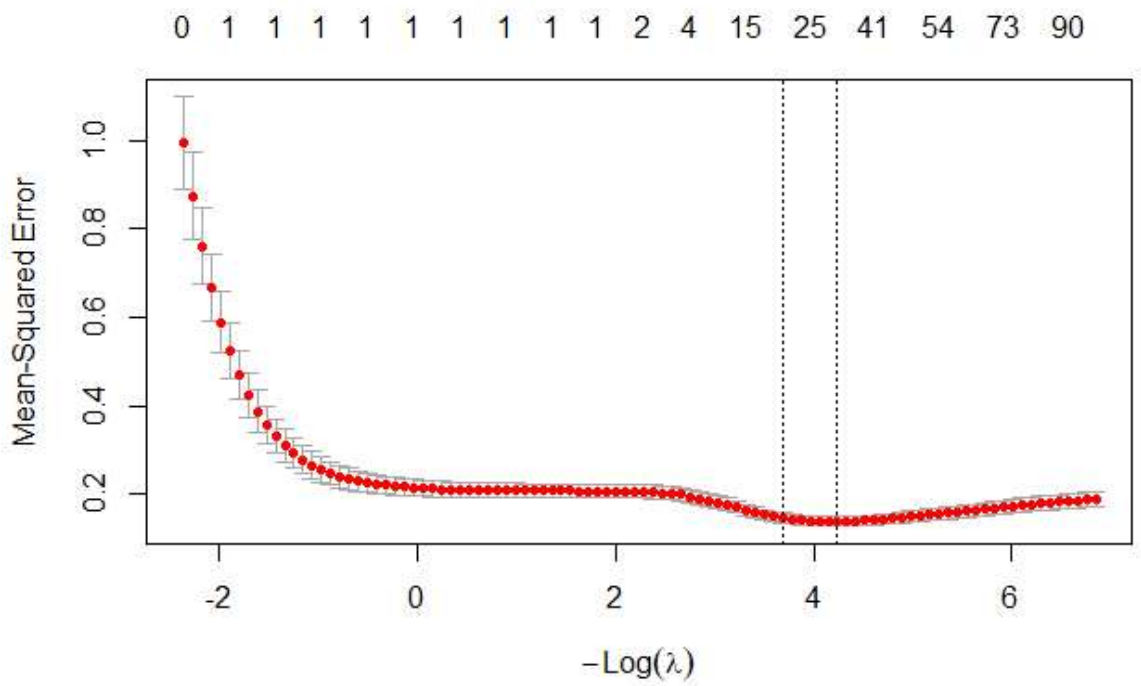
Source : Autrices

Annexe 9 : Courbe des lambdas avec la méthode Adaptive Lasso Ridge



Source : Autrices

Annexe 10 : Courbe des lambdas avec la méthode Adaptive Lasso Lasso



Source : Autrices